

Laboratório Estatístico Interativo

Grupo Paulo, Jhonata e Plínio · Prof. Romes Heriberto

1 · IDENTIFICAÇÃO

COMPONENTE	MATRÍCULA
Plínio Roberto Pereira	72650385
Paulo César Farias Silva	72650229
Jhonata Henrique Lima Bonadio	72650384

2 · LINK DOS DADOS CRUS

FONTE ORIGINAL — UCI MACHINE LEARNING REPOSITORY

<https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset>

Bike Sharing Dataset · 17.379 registros horários · Washington D.C., 2011–2012. O arquivo `hour.csv` também está versionado em `data/` no repositório, para que a aplicação rode sem depender da fonte.

3 · LINK DA SOLUÇÃO

REPOSITÓRIO PÚBLICO — GITHUB

<https://github.com/jhonatabonadio1/interactive-stat-lab>

Contém o código-fonte completo, o `README.md` com os componentes e as instruções de execução, o `RELATORIO.md` da atividade e os **612 testes automatizados**.

4 · LINK DO VÍDEO DE DEMONSTRAÇÃO

NÃO PRODUZIDO

A equipe optou por não realizar a gravação. Os demais entregáveis — código, testes, README e relatório — estão completos e disponíveis no repositório indicado no item 3.

Como executar do zero. Após clonar o repositório: `python3 -m venv .venv` → ativar o ambiente → `pip install -r requirements.txt` → `streamlit run app/principal.py` para a aplicação, ou `pytest` para os testes. O procedimento foi verificado num clone limpo a partir do GitHub, em ambiente virtual novo, usando apenas o que está declarado em `requirements.txt`.

Relatório completo. As fórmulas em notação matemática, as decisões de tratamento dos dados, a tabela de validação com a diferença medida por função e um print de cada módulo estão no `RELATORIO.md`, na raiz do repositório.

Laboratório Estatístico Interativo

Grupo Paulo, Jhonata e Plínio

O dataset

Bike Sharing Dataset (UCI, dataset 275) — registro horário do sistema público de bicicletas de Washington D.C. em 2011 e 2012, cruzado com dados meteorológicos. **17.379 registros, 8 variáveis numéricas e 7 categóricas.** Escolhido porque cada módulo encontra nele um caso natural: uma contagem (aluguéis por hora), uma variável aproximadamente simétrica (temperatura), uma com cauda longa (vento) e uma quase uniforme (hora do dia). Na preparação descobrimos que o `Readme.txt` do próprio dataset traz a fórmula errada de desnormalização da temperatura — superestima todos os meses em cerca de 6 °C. Conferimos contra a climatologia real da cidade e adotamos a fórmula correta.

Módulos implementados

1 · Descritiva	Tabela de frequências com classes por Sturges, todas as medidas de centro e dispersão, histograma, boxplot, outliers pelo IQR e interpretação textual gerada automaticamente dos números.
2 · Probabilidade	Monte Carlo da Lei dos Grandes Números (moeda e dado) e do Teorema Central do Limite sobre variável real, com n° de repetições, tamanho de amostra e semente sob controle do usuário.
3 · Distribuições	Normal, Exponencial, Uniforme e Poisson sobrepostas ao histograma, com parâmetros estimados dos próprios dados e medida objetiva da qualidade do ajuste.
4 · Regressão	Dispersão, correlação, reta de mínimos quadrados, R^2 , predição interativa com aviso de extrapolação, diagnóstico de resíduos e alerta sobre causalidade.

Regra de ouro. Toda medida exibida ao usuário é calculada por código nosso, a partir da fórmula explícita, usando apenas o módulo `math` da biblioteca padrão. O histograma vem da nossa tabela de classes e o boxplot dos nossos quartis — sem `plt.hist` ou `plt.boxplot`. **Validação: 612 testes automatizados** comparando cada função com NumPy e SciPy sobre sete conjuntos de dados, com tolerância relativa de 10^{-9} . Doze funções batem de forma exata; a maior divergência de todas é $1,7 \times 10^{-10}$.

AS TRÊS DESCOBERTAS

1 · Ser uma contagem não faz de uma variável uma Poisson

O total de aluguéis por hora é um inteiro não negativo — o caso de livro-texto da Poisson. Foi o **pior ajuste** de todos os candidatos testados (distância 0,8422, contra 0,1061 da Exponencial). O índice de dispersão Var/λ vale **173,66** quando deveria valer 1. A causa é conceitual: a Poisson supõe taxa constante, mas a demanda vai de 6 bicicletas às 4h a 461 às 17h. Não existe um λ único, existe um $\lambda(t)$.

2 · O coeficiente de Pearson subestimou em 3x o efeito da hora do dia

Pela correlação, a hora parece menos importante que a temperatura ($r = 0,3941$ contra 0,4048). Mas o diagrama de dispersão revela **dois picos** — 8h e 17–18h, o padrão casa–trabalho — que uma reta não descreve. A razão de correlação η^2 , que não pressupõe forma alguma, mostra que a hora explica **50,2%** da variação, contra os 15,5% que o modelo linear capta. Correlação perto de zero não significa ausência de relação, e sim ausência de relação *linear*.

3 · O TCL não só funciona sobre dados torcidos, como acerta o número

A população tem assimetria de 0,7850 e coeficiente de variação de 95,7%. Ainda assim, a assimetria das médias amostrais cai para **0,0255** com $n = 200$ — redução de 31x. Mais do que isso: o erro padrão observado bate com o $\sigma/\sqrt{n}$ previsto com erro inferior a **0,5%** em $n = 30$, e a curva Normal sobreposta não foi ajustada aos dados simulados — seus parâmetros vêm da população, calculados antes de a simulação começar.